

R para el Análisis Econométrico

Módulo 1: Fundamentos Estadísticos en R

José Burgos | ASOECO

07-09-2025

Section 1

Parte I: Fundamentos de R y RStudio

Bienvenida a R y RStudio

- ¿Qué es R? Un lenguaje de programación para computación estadística y gráficos.
- ¿Qué es RStudio? El Entorno de Desarrollo Integrado (IDE).
- Filosofía de R: código abierto, extensible a través de paquetes y con una gran comunidad.

Hacer las cosas bien desde el inicio

- Buenas prácticas desde el inicio: Investigación Reproducible.
- Introducción al concepto de proyectos en RStudio para mantener el trabajo organizado.
- Entorno de trabajo y creación de un primer proyecto.

Manejo del entorno y flujo de trabajo

- Scripts de R: Cómo escribir y ejecutar código desde un archivo .R.
- Atajos de teclado clave en RStudio para agilizar el trabajo (ejecutar código, asignación, pipe).

Section 2

Primeros pasos en la programación con R

Operadores aritméticos

Tal como sugiere su nombre, estos operadores se emplea específicamente para realizar cálculos aritméticos. Es factible efectuar estas operaciones utilizando datos tanto enteros como numéricos.

Operador	Operación	Ejemplo	Resultado
+	Suma	$5+3$	8
-	Resta	$5-3$	2
*	Multiplicación	$5*3$	15
/	División	$5/3$	1.666667
^	Potencia	5^3	125
%%	División entera	$5\%\%3$	2

El orden de las operaciones es similar al que se usa en matemáticas: primero se resuelven las potencias, luego las multiplicaciones y divisiones, y finalmente las sumas y restas.

Operadores relacionados

Se usan los operadores lógicos para hacer comparaciones y su resultado siempre será TRUE o FALSE (verdadero o falso, respectivamente)

Operador	Comparación	Ejemplo	Resultado
<	Menor que	5 < 3	FALSE
<=	Menor o igual que	5 <= 3	FALSE
>	Mayor que	5 > 3	TRUE
>=	Mayor o igual que	5 >= 3	TRUE
==	Exactamente igual que	5 == 3	FALSE
!=	No es igual que	5 != 3	TRUE

Casi siempre cuando se hacen comparaciones siempre obtendremos TRUE o FALSE.

Operadores lógicos

Los operadores lógicos son usados para describir relaciones lógicas, expresadas como verdadero o falso.

Operador	Comparación
$x \mid y$	x ó y es verdadero
$x \& y$	x Y y son verdaderos
$!x$	x no es verdadero

Advertencia

- \mid devuelve TRUE si alguno de los datos es TRUE
- $\&$ solo devuelve TRUE si ambos datos es TRUE
- \mid solo devuelve FALSE si ambos datos son FALSE
- $\&$ devuelve FALSE si alguno de los datos es FALSE

Operadores de asignación

Los operadores de asignación son los más importantes, nos permiten asignar datos a variables. Se recomienda utilizar `<-` a la hora de asignar.

```
juan <- 5  
jose = 5
```

Consideraciones:

- Los nombres de las variables deben comenzar con una letra (a-z, A-Z).
- No pueden comenzar con un número, contener espacios o caracteres especiales (% , \$, & , etc.), excepto el guion bajo (_).
- R es sensible a mayúsculas y minúsculas (por ejemplo, edad y Edad son variables diferentes).

Section 3

Tipos de Datos y Estructuras

Tipos de datos

Los tipos de datos más común en R son:

Tipo	Ejemplo	Nombre en inglés
Entero	1	integer
Numérico	1.3	numeric
Cadena de texto	"uno"	character
Factor	uno	factor
Lógico	TRUE	logical
Perdido	NA	NA
Vacio	NULL	null

Para consultar el tipo de datos, usaremos la función `class()`

Podemos manipular los datos en R, o más precisamente, realizar conversiones forzadas de un tipo a otro utilizando las funciones de la familia `as.integer()`, `as.numeric()`, `as.character()`, `as.factor()`, `as.logical()`, `as.null()`. Todas estas funciones trabajan con datos y vectores.

Ejemplos:

```
as.character(5)
```

```
## [1] "5"
```

```
as.logical(1)
```

```
## [1] TRUE
```

Advertencia

Se debe utilizar estas funciones con cuidado, ya que pueden generar resultados inesperados. Siempre se debe evaluar antes de convertir un tipo de dato a otro. Por ejemplo: si pasas un texto a numérico, el resultado será NA. Si pasas un número a lógico, el resultado será TRUE si el número es distinto de cero y FALSE si es cero, pero si es mayor de 1, el resultado será TRUE.

Vectores

Un vector es una colección de uno o más datos del mismo tipos. Los vectores siempre tienen tres propiedades:

- 1 **Tipo:** El tipo de dato que contiene el vector (numérico, carácter, lógico, etc.)
- 2 **Longitud:** El número de elementos en el vector.
- 3 **Atributos:** Metadatos adicionales que describen el vector (como nombres de elementos). Por ejemplo, un vector puede tener nombres para cada uno de sus elementos: `c(a = 1, b = 2, c = 3)`.

Vectores

```
vec <- 1 # Crear un vector
# Vectores de más de un elemento usar c()
vector1 <- c(1,3,4,5,6)
vector2 <- 1:10

vector2 + 2 # Vectorización
```

```
##      [1]  3  4  5  6  7  8  9 10 11 12
```

Data frames

Un data frame es una colección de vectores de igual longitud, donde cada vector representa una columna y cada fila representa una observación. Los data frames son especialmente útiles para manejar conjuntos de datos tabulares, como los que se encuentran comúnmente en análisis estadísticos y científicos.

```
head(iris, n = c(3,3))
```

##	Sepal.Length	Sepal.Width	Petal.Length
## 1	5.1	3.5	1.4
## 2	4.9	3.0	1.4
## 3	4.7	3.2	1.3

Creando un data frames

```
# Crear vectores
nombre <- c("Ana", "Luis", "Marta")
edad <- c(23, 30, 25)
peso <- c(55.5, 70.2, 60.3)

# Crear data frame
estudiantes <- data.frame(nombre, edad, peso)
```

Acceder a los elementos de un data frame

```
# Acceder a una columna  
estudiantes$nombre
```

```
## [1] "Ana"    "Luis"   "Marta"
```

```
# Acceder a una fila  
estudiantes[1, ]
```

```
##   nombre edad peso  
## 1     Ana   23 55.5
```

Acceder a los elementos de un data frame

```
# Acceder a un elemento específico  
estudiantes[1, 2]
```

```
## [1] 23
```

```
# Acceder a múltiples filas y columnas  
estudiantes[1:2, c("nombre", "edad")]
```

```
##   nombre edad  
## 1    Ana   23  
## 2   Luis   30
```

Section 4

Ejercicios practicos

- 1 Crea un vector llamado `edades` que contenga las edades de cinco personas. Ejemplo: 25, 30, 22, 28, 35. Luego, muestra el vector en la consola.
- 2 Utiliza operadores aritméticos para calcular la suma, resta, multiplicación y división de dos números. Asigna el resultado de cada operación a una variable diferente y muestra los resultados en la consola.
- 3 Crea un data frame llamado `estudiantes` con las siguientes columnas: `nombre` (carácter), `edad` (numérico) y `aprobado` (lógico). Llena el data frame con datos de cinco estudiantes.
- 4 Utiliza la función `class()` para verificar el tipo de datos de cada columna en el data frame `estudiantes`.

```
# Ejercicio 1
```

```
edades <- c(25, 30, 22, 28, 35)
```

```
edades
```

```
## [1] 25 30 22 28 35
```

Resultados

```
# Ejercicio 2
```

```
num1 <- 10
```

```
num2 <- 5
```

```
suma <- num1 + num2
```

```
resta <- num1 - num2
```

```
multiplicacion <- num1 * num2
```

```
division <- num1 / num2
```

```
suma; resta; division; multiplicacion
```

```
## [1] 15
```

```
## [1] 5
```

```
## [1] 2
```

```
## [1] 50
```

Ejercicio 3

```
nombre <- c("Ana", "Luis", "Marta", "Carlos", "Sofia")
edad <- c(23, 30, 25, 28, 22)
aprobado <- c(TRUE, FALSE, TRUE, TRUE, FALSE)
estudiantes <- data.frame(nombre, edad, aprobado)
estudiantes
```

```
##   nombre edad aprobado
## 1   Ana   23     TRUE
## 2  Luis   30    FALSE
## 3  Marta   25     TRUE
## 4 Carlos   28     TRUE
## 5  Sofia   22    FALSE
```



```
# Ejercicio 4
```

```
class(estudiantes$nombre)
```

```
## [1] "character"
```

```
# Ejercicio 4
```

```
class(estudiantes$aprobado)
```

```
## [1] "logical"
```

Section 5

Funciones y paquetes

Las funciones son bloques de código reutilizables que realizan tareas específicas. En R, las funciones se definen utilizando la palabra clave `function()`. Las funciones pueden aceptar argumentos (entradas) y devolver valores (salidas).

```
# Estructura básica de una función
mi_funcion <- function(arg1, arg2) {
  # Código que realiza una tarea
  resultado <- arg1 + arg2
  return(resultado)
}
```

Si queremos acceder a la documentación de una función en especial, podemos ejecutar `?mean` o `help(mean)`

Los paquetes son colecciones de funciones, datos y documentación que extienden las capacidades básicas de R. Existen miles de paquetes disponibles para diversas tareas, desde análisis estadísticos hasta visualización de datos.

Instalación y carga de paquetes

Para instalar un paquete, usamos la función

```
install.packages("tidyverse")
```

Una vez instalado, debemos cargar el paquete

en nuestra sesión de R utilizando:

```
library(tidyverse)
```

Funciones más usadas en dplyr

Función	Descripción
<code>filter()</code>	Filtra filas según condiciones específicas.
<code>select()</code>	Selecciona columnas específicas de un data frame.
<code>group_by()</code>	Agrupar datos según una o más columnas.
<code>mutate()</code>	Crea nuevas columnas o modifica existentes.
<code>arrange()</code>	Ordena filas según una o más columnas.
<code>summarise()</code>	Resume múltiples valores en un solo valor.

Ejemplos

```
library(tidyverse)
filter(estudiantes, edad > 25)
```

```
##   nombre edad aprobado
## 1   Luis   30     FALSE
## 2 Carlos   28      TRUE
```

```
select(estudiantes, nombre, edad)
```

```
##   nombre edad
## 1   Ana   23
## 2   Luis   30
## 3  Marta   25
## 4 Carlos   28
## 5  Sofia   22
```

Ejemplos

```
summarise(  
  group_by(estudiantes, aprobado),  
  edad_media = mean(edad), edad_max = max(edad)  
)
```

```
## # A tibble: 2 x 3  
##   aprobado edad_media edad_max  
##   <lgl>         <dbl>    <dbl>  
## 1 FALSE         26        30  
## 2 TRUE          25.3       28
```

Pipe

El operador pipe (`%>%` o `|>`) es una herramienta poderosa en R que permite encadenar múltiples operaciones de manera legible y concisa. Facilita la lectura del código al expresar una secuencia de transformaciones de datos.

```
# Ejemplo usando el operador pipe  
estudiantes %>%  
  filter(edad > 25) %>%  
  select(nombre, edad) %>%  
  arrange(desc(edad))
```

```
##   nombre edad  
## 1   Luis   30  
## 2 Carlos   28
```


Section 6

Importación de datos

Podemos cargar datos de diferentes formatos, como CSV, Excel, entre otros. Vamos a cargar la base de datos de la Encuesta Nacional de Fuerza de Trabajo (ENFCT) que se encuentra en formato excel.

Con el paquete `readxl` podemos leer archivos de Excel (`.xlsx`, `.xls`).

```
library(readxl)
enfct_2019 <- read_excel("enfct_2019.xlsx")
```

Una vez que hemos importado los datos, es importante evaluar su estructura y contenido para entender qué tipo de análisis podemos realizar. Algunas funciones útiles para esta tarea son:

```
# Ver las primeras filas del data frame  
head(enfct_2019)  
# La más recomendable es glimpse() del paquete dplyr  
glimpse(enfct_2019)
```

Section 7

Manipulación de datos con dplyr

Manipulación de datos con dplyr

El paquete `dplyr` es parte del ecosistema `tidyverse` y proporciona una gramática coherente para manipular datos. A continuación, se presentan algunas de las funciones más comunes y útiles de `dplyr` para transformar y analizar datos.

Tips opcional

Se recomienda limpiar los nombres de las variables, para evitar problemas al momento de manipular los datos. Para esto, usaremos la función `clean_names()` del paquete `janitor`.

Manipulación de datos con dplyr

```
library(janitor)
enfct_2019 <- clean_names(enfct_2019)
```

```
enfct_2019 %>%
  select(1:3) %>%
  tail(3) %>%
  glimpse()
```

```
## Rows: 3
## Columns: 3
## $ ano          <dbl> 2019, 2019, 2019
## $ id_provincia <dbl> 12, 12, 12
## $ factor_expansion <dbl> 173.7651, 173.7651, 173.7651
```

Primer paso:

Definimos las variables que nos interesa y evaluamos su contenido. En este ejercicio vamos a seleccionar las variables `edad`, `sexo`, `des_provincia`, `sueldo_bruto_ap_monto`, `estado_civil` y `nivel_ultimo_ano_aprobado`.

```
enfct_2019 <- enfct_2019 %>%  
  select(edad, sexo, des_provincia,  
         sueldo_bruto_ap_monto, estado_civil,  
         nivel_ultimo_ano_aprobado)
```

Manipulación de datos con dplyr

Evaluamos el contenido de las variables e identificamos los cambios necesarios para nuestros datos.

```
enfct_2019 %>%  
  tail(3) %>%  
  glimpse()
```

```
## Rows: 3  
## Columns: 6  
## $ edad                <dbl> 26, 4, 32  
## $ sexo                 <chr> "F", "F", "M"  
## $ des_provincia        <chr> "LA ROMANA", "LA ROMANA",  
## $ sueldo_bruto_ap_monto <dbl> 2500, NA, 2000  
## $ estado_civil         <chr> "Union libre", NA, "Separ  
## $ nivel_ultimo_ano_aprobado <chr> "Secundario", "Ninguno",
```


Manipulación de datos con dplyr

Con `count`, podemos identificar varios detalles: los valores dentro de la variables y la frecuencia de cada valor. Una segunda opción es la función `distinct`, que nos muestra los valores únicos dentro de una variable.

```
enfct_2019 %>%  
  count(sexo)
```

```
## # A tibble: 2 x 2  
##   sexo      n  
##   <chr> <int>  
## 1 F      41872  
## 2 M      41159
```

Manipulación de datos con dplyr

```
enfct_2019 %>%  
  distinct(estado_civil)
```

```
## # A tibble: 7 x 1  
##   estado_civil  
##   <chr>  
## 1 Separado(a)  
## 2 <NA>  
## 3 Casado(a)  
## 4 Soltero(a)  
## 5 Union libre  
## 6 Viudo(a)  
## 7 Divorciado(a)
```

Manipulación de datos con dplyr

Vamos a realizar algunos cambios en las variables que seleccionamos. Primero, vamos a cambiar los valores de la variable sexo, que actualmente tiene los valores F y M, por Femenino y Masculino. Para esto, usaremos la función `mutate()` junto con `recode`.

```
enfct_2019 <- enfct_2019 %>%  
  mutate(sexo = recode(sexo,  
                        "F" = 1,  
                        "M" = 0))  
enfct_2019 %>% distinct(sexo)
```

```
## # A tibble: 2 x 1  
##   sexo  
##   <dbl>  
## 1     1  
## 2     0
```

Manipulación de datos con dplyr

Vamos a cambiar los valores de la variable `estado_civil`, que actualmente tiene los valores `Separado(a)`, `Casado(a)`, `Soltero(a)`, `Union libre`, `Viudo(a)`, `Divorciado(a)`, por `Casado` y `Soltero`. Para esto, usaremos la función `mutate()` junto con `case_when()`.

```
enfct_2019 <- enfct_2019 %>%  
  mutate(estado_civil = case_when(  
    estado_civil %in% c(  
      "Casado(a)", "Union libre") ~ "Casado",  
    estado_civil %in% c(  
      "Soltero(a)", "Viudo(a)", "Divorciado(a)",  
      "Separado(a)") ~ "Soltero"  
  ))
```

Manipulación de datos con dplyr

```
enfct_2019 %>% distinct(estado_civil)
```

```
## # A tibble: 3 x 1  
##   estado_civil  
##   <chr>  
## 1 Soltero  
## 2 <NA>  
## 3 Casado
```

Section 8

Ejercicios prácticos

- 1 Carga el conjunto de datos `mtcars` que viene incluido en R. Utiliza la función `head()` para ver las primeras filas del conjunto de datos.
- 2 Selecciona las columnas `mpg`, `cyl`, y `hp` del conjunto de datos `mtcars` y crea un nuevo data frame llamado `mtcars_subset`.
- 3 Filtra las filas del data frame `mtcars_subset` para incluir solo los autos con más de 6 cilindros (`cyl > 6`). Guarda el resultado en un nuevo data frame llamado `mtcars_filtered`.
- 4 Crea una nueva columna en el data frame `mtcars_filtered` llamada `power_to_weight` que sea el resultado de dividir la potencia (`hp`) por el peso (`wt`). Utiliza la función `mutate()` para esto.

Section 9

Resultados

Resultados

```
data(mtcars)
# Ejercicio 1
head(mtcars, 6)
```

##	mpg	cyl	disp	hp	drat	wt	qsec	vs	am
## Mazda RX4	21.0	6	160	110	3.90	2.620	16.46	0	1
## Mazda RX4 Wag	21.0	6	160	110	3.90	2.875	17.02	0	1
## Datsun 710	22.8	4	108	93	3.85	2.320	18.61	1	1
## Hornet 4 Drive	21.4	6	258	110	3.08	3.215	19.44	1	0
## Hornet Sportabout	18.7	8	360	175	3.15	3.440	17.02	0	0
## Valiant	18.1	6	225	105	2.76	3.460	20.22	1	0

Ejercicio 2

```
mtcars %>%  
  select(mpg, cyl, hp) %>%  
  head(6)
```

##	mpg	cyl	hp
## Mazda RX4	21.0	6	110
## Mazda RX4 Wag	21.0	6	110
## Datsun 710	22.8	4	93
## Hornet 4 Drive	21.4	6	110
## Hornet Sportabout	18.7	8	175
## Valiant	18.1	6	105

```
# Ejercicio 3
```

```
mtcars %>%
```

```
  filter(cyl > 6) %>%
```

```
  head(6)
```

##		mpg	cyl	disp	hp	drat	wt	qsec	vs	am
##	Hornet Sportabout	18.7	8	360.0	175	3.15	3.44	17.02	0	0
##	Duster 360	14.3	8	360.0	245	3.21	3.57	15.84	0	0
##	Merc 450SE	16.4	8	275.8	180	3.07	4.07	17.40	0	0
##	Merc 450SL	17.3	8	275.8	180	3.07	3.73	17.60	0	0
##	Merc 450SLC	15.2	8	275.8	180	3.07	3.78	18.00	0	0
##	Cadillac Fleetwood	10.4	8	472.0	205	2.93	5.25	17.98	0	0

Resultados

```
# Ejercicio 4
```

```
mtcars %>%
```

```
  mutate(
```

```
    power_to_weight = hp / wt,
```

```
    .before = mpg
```

```
  ) %>%
```

```
head(6)
```

##	power_to_weight	mpg	cyl	disp	hp	drat	
## Mazda RX4	41.98473	21.0	6	160	110	3.90	2.62
## Mazda RX4 Wag	38.26087	21.0	6	160	110	3.90	2.875
## Datsun 710	40.08621	22.8	4	108	93	3.85	2.78
## Hornet 4 Drive	34.21462	21.4	6	258	110	3.08	3.15
## Hornet Sportabout	50.87209	18.7	8	360	175	3.15	3.44
## Valiant	30.34682	18.1	6	225	105	2.76	3.46
##	carb						
## Mazda RX4	4						

Section 10

Exportación de datos

Una vez que hemos manipulado y analizado nuestros datos, es importante guardar los resultados para su uso futuro o para compartirlos con otros. R ofrece varias funciones para exportar datos a diferentes formatos, como CSV, Excel y RDS.

Exportar a excel con openxlsx

El paquete openxlsx permite exportar data frames a archivos de Excel (.xlsx) de manera sencilla y eficiente.

```
# Pasos para exportar un data frame a Excel  
library(openxlsx)  
write.xlsx(enfct_2019, file = "enfct_2019_new.xlsx")
```

Section 11

Estadística descriptiva

Medidas de tendencia central

Las medidas de tendencia central son estadísticas que describen el centro o la ubicación típica de un conjunto de datos. Las tres medidas más comunes son la media, la mediana y la moda.

$$\text{Media} = \frac{\sum_{i=1}^n x_i}{n}$$

$$\text{Mediana} = \begin{cases} \frac{x_{(n/2)} + x_{(n/2+1)}}{2}, & \text{si } n \text{ es par} \\ x_{((n+1)/2)}, & \text{si } n \text{ es impar} \end{cases}$$

Medidas de tendencia central

Medida	Descripción	Función en R
Media	El promedio aritmético de los datos.	<code>mean()</code>
Mediana	El valor central cuando los datos están ordenados.	<code>median()</code>
Moda	El valor que aparece con mayor frecuencia.	No hay función nativa, pero se puede calcular con <code>table()</code> y <code>which.max()</code>

Medidas de tendencia central

```
enfct_2019 %>%  
  summarise(  
    # na.rm = TRUE para ignorar los valores perdidos  
    media = mean(edad, na.rm = TRUE),  
    mediana = median(edad, na.rm = TRUE)  
  )
```

```
## # A tibble: 1 x 2  
##   media mediana  
##   <dbl>   <dbl>  
## 1  31.3     28
```

Medidas de dispersión

Las medidas de dispersión describen la variabilidad o dispersión de un conjunto de datos. Las dos medidas más comunes son la desviación estándar y la varianza.

Varianza (s^2)

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

Desviación Estándar (s)

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

Medidas de dispersión

Medida	Descripción	Función en R
Varianza	La media de las desviaciones al cuadrado respecto a la media.	<code>var()</code>
Desviación Estándar	La raíz cuadrada de la varianza, que mide la dispersión en las mismas unidades que los datos.	<code>sd()</code>

Medidas de dispersión

```
enfct_2019 %>%  
  summarise(  
    varianza = var(edad, na.rm = TRUE),  
    desviacion_estandar = sd(edad, na.rm = TRUE)  
  )
```

```
## # A tibble: 1 x 2  
##   varianza desviacion_estandar  
##   <dbl>         <dbl>  
## 1    466.           21.6
```

Las medidas de posición describen la ubicación relativa de un valor dentro de un conjunto de datos. Las medidas más comunes son los cuartiles, percentiles y cuantiles.

Percentil: El percentil P_k es el valor que divide el conjunto de datos en (k) partes iguales. Por ejemplo, el percentil 25 (P25) es el valor por debajo del cual se encuentra el 25% de los datos.

P_k = Valor que divide el conjunto de datos en k partes iguales

Cuartiles: Los cuartiles Q_1 , Q_2 y Q_3 son valores que dividen el conjunto de datos en cuatro partes iguales. Q_1 es el percentil 25, Q_2 es la mediana (percentil 50) y Q_3 es el percentil 75.

Q_1, Q_2, Q_3 = Valores que dividen el conjunto de datos en cuatro partes iguales

Cuantiles: Los cuantiles q_p son valores que dividen el conjunto de datos en p partes iguales. Por ejemplo, el cuantil 0.25 ($q_{0.25}$) es el valor por debajo del cual se encuentra el 25% de los datos.

q_p = Valor que divide el conjunto de datos en p partes iguales

Resumiendo nuestras variables

```
enfct_2019 %>%  
  summarise(  
    q1 = quantile(edad, 0.25, na.rm = TRUE),  
    q2 = quantile(edad, 0.50, na.rm = TRUE),  
    q3 = quantile(edad, 0.75, na.rm = TRUE)  
  )
```

```
## # A tibble: 1 x 3  
##       q1      q2      q3  
##   <dbl> <dbl> <dbl>  
## 1     13     28     47
```

Section 12


Gráficos en R con ggplot2

R tiene funciones nativas para crear gráficos básicos, como `plot()`, `hist()`, `boxplot()`, entre otras. Estas funciones son fáciles de usar y permiten crear gráficos rápidamente. Su desventaja principal es que la personalización y la creación de gráficos complejos pueden ser limitadas.

Dispersión en R base

```
# Gráfico de dispersión
```

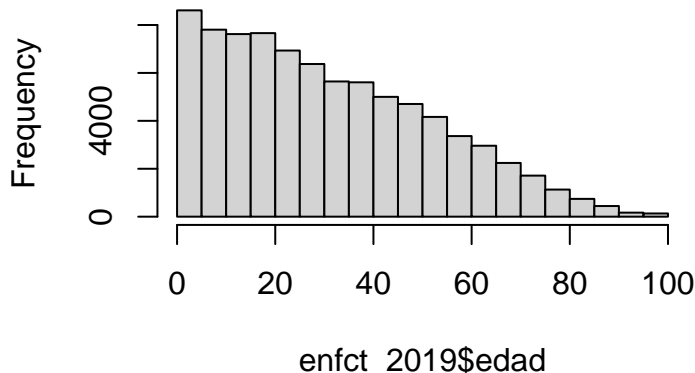
```
plot(enfct_2019$edad, enfct_2019$sueldo_bruto_ap_monto)
```



Histograma en R base

```
hist(enfct_2019$edad, main = "Histograma de Edad")
```

Histograma de Edad



Los gráficos con ggplot2 se basan en la “gramática de gráficos”, que permite construir gráficos capa por capa. Esto facilita la creación de gráficos complejos y altamente personalizados. Las capas principales incluyen:

- `ggplot()`: El lienzo inicial.
- `aes()`: Mapeo de variables a estéticas (ejes, color, forma).
- Geoms: Las representaciones visuales de los datos (puntos, barras, líneas).


Dispersión con ggplot2

```
library(ggplot2)

plot_dispersion <- enfct_2019 %>%
  ggplot(aes(x = edad, y = sueldo_bruto_ap_monto)) +
  geom_point() +
  labs(title = "Gráfico de Dispersión: Edad vs Sueldo Bruto",
       x = "Edad",
       y = "Sueldo Bruto") +
  theme_minimal()
```

```
plot_dispersion
```

Gráfico de Dispersión: Edad vs Sueldo Br



Histograma con ggplot2

```
plot_histograma <- enftc_2019 %>%  
  ggplot(aes(x = edad)) +  
  geom_histogram(  
    binwidth = 5, fill = "blue",  
    color = "black", alpha = 0.7) +  
  labs(title = "Histograma de Edad",  
        x = "Edad",  
        y = "Frecuencia") +  
  theme_minimal()
```

Histograma con ggplot2

```
plot_histogram
```





Gráfico de boxplot

```
plot_boxplot <- enfct_2019 %>%  
  ggplot(aes(x = factor(sexo), y = sueldo_bruto_ap_monto)) +  
  geom_boxplot(outliers = FALSE) +  
  labs(title = "Boxplot de Sueldo Bruto por Sexo",  
        x = "Mujer",  
        y = "Sueldo Bruto") +  
  theme_minimal()
```

Gráfico de boxplot

```
plot_boxplot
```



Section 13

Ejercicios prácticos

- 1 Calcula los estadísticos aprendidos aquí para el ingreso de los individuos, edad.
- 2 Calcula los estadísticos aprendidos aquí para el ingreso de los individuos, segmentando por sexo, y luego por estado civil.
- 3 Realiza el ejercicio anterior, pero ahora segmentando por sexo, y luego por estado civil.
- 4 Realiza un gráfico de dispersión entre edad y sueldo bruto, coloreando por sexo.

- 5 Calcula el promedio de sueldo bruto por provincia y realiza un gráfico de barras con los resultados. Sientete libre en personalizar el gráfico.
- 6 ¿Los ingresos más bajo a que provincia pertenecen?
- 7 ¿Son los solteros más joven que los casados?
- 8 ¿Los hombres ganan más que las mujeres?

Section 14

Referencia

Mendoza Vega, J. B. (2020). *R para principiantes: Introducción al análisis de datos con R y RStudio* (4a ed.). Editorial Académica Española.

<https://bookdown.org/jboscomendoza/r-principiantes4/>

Wickham, H., & Golemund, G. (2017). *R para ciencia de datos* (1a ed.). Ediciones Díaz de Santos. <https://r4ds.hadley.nz/index.html>

Villarroel-Riquelme, F. (2020). *Introducción a la Estadística con R y RStudio*. https://rpubs.com/franciscovillarroel/estadistica_r

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning: with Applications in R*. Springer. <https://www.econometrics-with-r.org/1-introduction.html>